数据挖掘大作业三：分类与聚类

1 对数据集进行处理

本次作业选用数据集[https://www.kaggle.com/c/titanic/data]，利用 Python 中的 pandas 库进行 csv 数据文件的读取，对数据集进行预处理，以适合分类和聚类算法。

（1）处理缺失数据；

用 scikit-learn 中的 RandomForest 来拟合一下'Age','Fare', 'Parch', 'SibSp', 'Pclass'等字段的缺失数据：

```
def set_missing_ages(df):

    # 把已有的数值型特征取出来丢进Random Forest Regressor中
    age_df = df[['Age','Fare', 'Parch', 'SibSp', 'Pclass']]

    # 乘客分成已知年龄和未知年龄两部分
    known_age = age_df[age_df.Age.notnull()].as_matrix()
    unknown_age = age_df[age_df.Age.isnull()].as_matrix()

    # y即目标年龄
    y = known_age[:, 0]

    # X即特征属性值
    X = known_age[:, 1:]

    # fit到RandomForestRegressor之中
    rfr = RandomForestRegressor(random_state=0, n_estimators=2000, n_jobs=-1)
    rfr.fit(X, y)

    # 用得到的模型进行未知年龄结果预测
    predictedAges = rfr.predict(unknown_age[:, 1::])

    # 用得到的预测结果填补原缺失数据
    df.loc[ (df.Age.isnull()), 'Age' ] = predictedAges

    return df, rfr
```

按 Cabin 有无数据，将这个属性处理成 Yes 和 No 两种类型：

```
def set_Cabin_type(df):
    df.loc[ (df.Cabin.notnull()), 'Cabin' ] ="Yes"
    df.loc[ (df.Cabin.isnull()), 'Cabin' ] = "No"
    return df
```

（2）将标称数据转化为数值数据；

```
#将标称型数据转化为数值型数据
df.loc[df['Sex'] == 'male','Sex'] = 1
df.loc[df['Sex'] == 'female','Sex'] = 0
```

（3）对类目型的特征因子化；

```
#特征因子化
dummies_Cabin = pandas.get_dummies(data_train['Cabin'], prefix= 'Cabin')

dummies_Embarked = pandas.get_dummies(data_train['Embarked'], prefix= 'Embarked')

dummies_Sex = pandas.get_dummies(data_train['Sex'], prefix= 'Sex')

dummies_Pclass = pandas.get_dummies(data_train['Pclass'], prefix= 'Pclass')

df = pandas.concat([data_train, dummies_Cabin, dummies_Embarked, dummies_Sex, dummies_Pclass], axis=1)
```

（4）数值数据归一化处理；

```
#数值数据归一化处理
import sklearn.preprocessing as preprocessing
scaler = preprocessing.StandardScaler()
age_scale_param = scaler.fit(df['Age'].values.reshape(-1, 1))
df['Age_scaled'] = scaler.fit_transform(df['Age'].values.reshape(-1, 1), age_scale_param)
fare_scale_param = scaler.fit(df['Fare'].values.reshape(-1, 1))
df['Fare_scaled'] = scaler.fit_transform(df['Fare'].values.reshape(-1, 1), fare_scale_param)
```

2 分类算法

使用 Sklearn 中 train_test_split 随机划分训练集和测试集，从样本中随机的按比例选取 train data 和 testdata，用于测试分类算法的预测准确率。以下使用决策树和逻辑回归算法进行模型训练和预测。

```
from sklearn.cross_validation import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=33)
```

2.1 决策树

（1）选取数据中用于决策树模型训练的字段，用 Sklearn 中 DecisionTreeClassifier 进行决策树模型的训练：

```
X = data_train[["Pclass","Sex","SibSp","Parch"]]
y = data_train['Survived']
```

```
#决策树
dt=tree.DecisionTreeClassifier()
dt=dt.fit(X_train,y_train)
```

（2）输出预测准确性和详细的分类性能

```
# 从sklearn.metrics导入classification_report。
from sklearn.metrics import classification_report
# 输出预测准确性。
print(dt.score(X_test, y_test))
# 输出更加详细的分类性能。
y_predict = dt.predict(X_test)
print(classification_report(y_predict, y_test, target_names = ['died', 'survived']))
```

（3）预测准确性和详细的性能结果

```
0.8071748878923767
              precision    recall  f1-score   support

        died       0.91      0.80      0.85       153
    survived       0.65      0.83      0.73        70

avg / total       0.83      0.81      0.81       223
```

（4）决策树可视化代码及效果

```
feature_name = ["Pclass","Sex","SibSp","Parch"]
target_name = ["Survived","Died"]
dot_data = StringIO()
tree.export_graphviz(dt,out_file = dot_data,feature_names=feature_name,
                     class_names=target_name,filled=True,rounded=True,
                     special_characters=True)
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
graph.write_pdf("Decision_Tree.pdf")
```

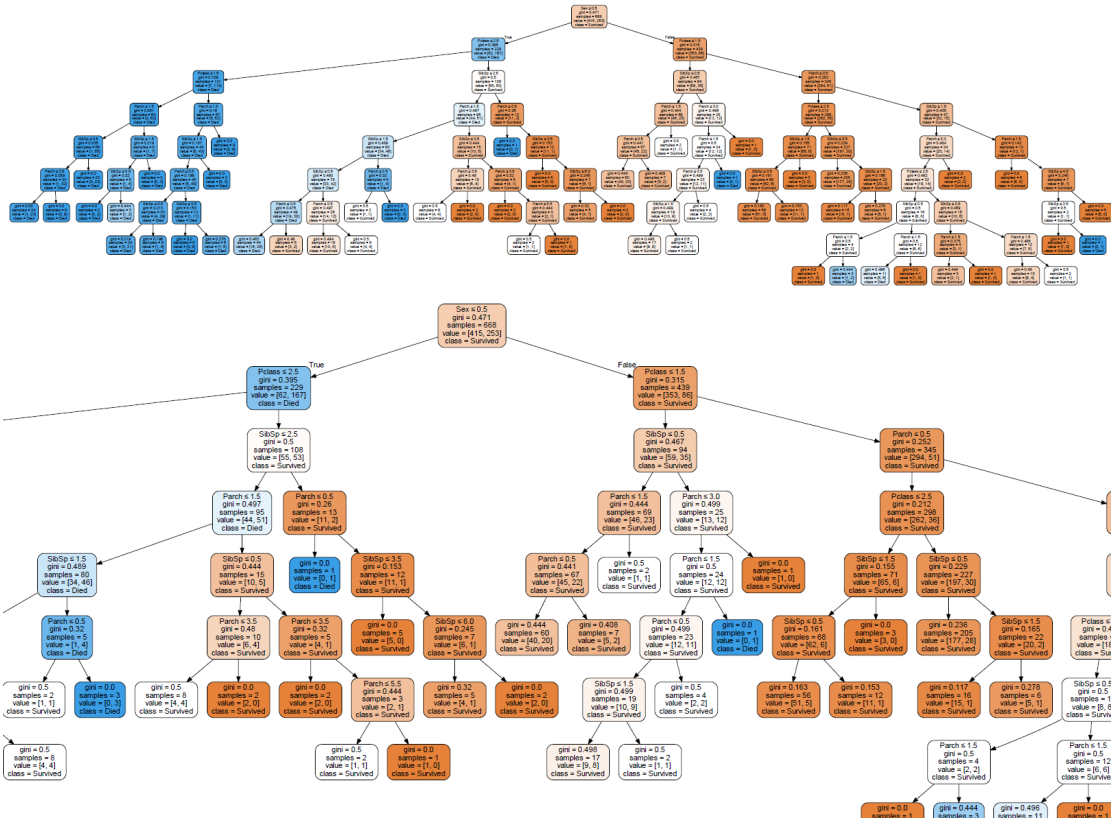

2.2 逻辑回归

（1）选取数据中用于逻辑回归模型训练的字段，用 Sklearn 中 LogisticRegression 进行逻辑回归模型的训练：

```
X = df[["Age","SibSp","Parch","Fare","Pclass","Sex"]]
y = df['Survived']
```

```
# fit到RandomForestRegressor之中
clf = linear_model.LogisticRegression(C=1.0, penalty='l1', tol=1e-6)
clf.fit(X_train, y_train)
```

（2）输出预测准确性和详细的分类性能：

```
predictions = clf.predict(X_test)
# 从sklearn.metrics导入classification_report。
from sklearn.metrics import classification_report
# 输出预测准确性。
print(clf.score(X_test, y_test))
# 输出更加详细的分类性能。
print(classification_report(predictions, y_test, target_names = ['died', 'survived']))
```

（3）预测准确性和详细的性能结果如下

```
0.8161434977578476
              precision    recall  f1-score   support

        died       0.87      0.83      0.85       141
    survived       0.73      0.79      0.76        82

avg / total       0.82      0.82      0.82       223
```

3 聚类算法

3.1 K-means

（1）选取数据中用于 K-means 聚类的数据字段，用 Sklearn 中 Kmeans 对数据进行 K-means 聚类：

```
X = data_train[["Pclass","Sex","SibSp","Parch","Age_scaled"]]
y = data_train['Survived']
```

```
y_pred = KMeans(n_clusters=4, random_state=0).fit_predict(X_train)
```

（2）利用 TSNE 进行降维处理并可视化聚类结果

```
iris = chj_load_file(X_train,y_pred)
X_tsne = TSNE(n_components=2,learning_rate=100).fit_transform(iris.data)
plt.figure(figsize=(12, 6))
plt.scatter(X_tsne[:, 0], X_tsne[:, 1], c=iris.target)
plt.colorbar()
plt.show()
```

可视化效果如下

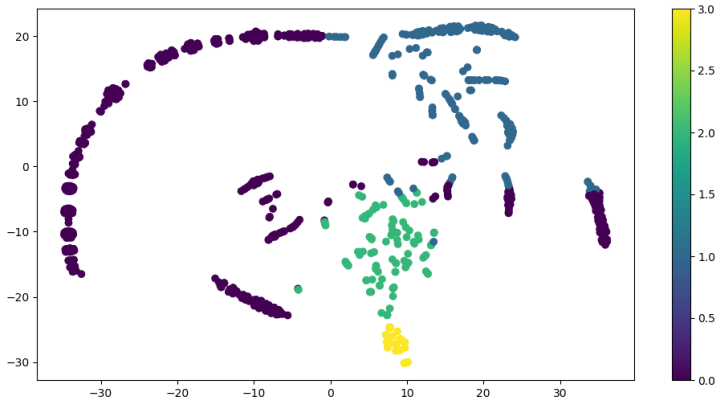

3.2 Birch

（1）选取数据中用于 Birch 聚类的数据字段，用 Sklearn 中 Birch 对数据进行 Birch 聚类：

```
X = data_train[["Pclass","Sex","SibSp","Parch","Age_scaled"]]
y = data_train['Survived']
```

```
y_Birch = Birch(n_clusters = None).fit_predict(X_train)
```

（2）利用 TSNE 进行降维处理并可视化聚类结果

```
iris_Birch = chj_load_file(X_train,y_Birch)
X_tsne_Birch = TSNE(n_components=2,learning_rate=100).fit_transform(iris_Birch.data)
plt.figure(figsize=(12, 6))
plt.scatter(X_tsne_Birch[:, 0], X_tsne_Birch[:, 1], c=iris_Birch.target)
plt.colorbar()
plt.show()
```

可视化效果如下